

Projet d'entrepôt de données des ventes automobiles

Résumé exécutif : À la suite de la validation du cahier des charges, j'ai achevé la phase fondatrice de conception et d'implémentation de l'entrepôt de données. L'analyse des besoins, l'architecture, l'initialisation du projet ainsi que les couches Bronze et Silver sont désormais terminées. La solution contient actuellement 2,5 millions de transactions de ventes automobiles chargées et validées dans SQL Server.

1. Synthèse de l'avancement

Epics	Name	Progress	
1	Requirements Analysis	100.00%	
2	Design Data Architecture OPEN	100.00%	
3	Project Initialization	100.00%	
4	Build Bronze layer	100.00%	
5	Build Silver layer	100.00%	

Cinq epics structurants terminés à 100 %.

Epic	Statut	Résultat principal
Analyse des besoins	Terminé	CDC validé
Conception de l'architecture des données	Terminé	Approche choisie et couches en médaillon conçues
Initialisation du projet	Terminé	Structure Git, base, schémas et règles de nommage
Construction de la couche Bronze	Terminé	Ingestion brute et validation de la source
Construction de la couche Silver	Terminé	Nettoyage, typage et validation de la qualité

2. Travaux réalisés durant la semaine


Des exigences validées à une base Bronze et Silver opérationnelle

A. Validation des exigences et planification

- Réception de la validation du cahier des charges, utilisé comme référence approuvée du projet.
- Confirmation du périmètre : entrepôt SQL Server, reporting Power BI, prévisions par machine learning et tableau de bord Streamlit.
- Analyse de la source Kaggle : environ 2,5 millions de lignes et neuf champs transactionnels.

B. Réflexion et conception de l'architecture

- Comparaison des options d'architecture et de modélisation : Data Warehouse, Data Lake, Lakehouse, Data Mesh, Inmon, Kimball, Data Vault et architecture en médaille.
- Choix de l'architecture en médaille pour séparer les données brutes, nettoyées et prêtes à l'usage métier, tout en assurant la traçabilité et une mise en œuvre simple.



Flux de haut niveau validé : source CSV -> tables Bronze -> tables Silver -> vues Gold -> outils de consommation.

C. Normes du projet et initialisation

Base de données	car_sales_dwh
Schémas	bronze, silver, gold
Nommage	snake_case en anglais ; préfixe source dealer ; préfixe métadonnées dwh_
ETL	T-SQL uniquement ; chargement complet par lots avec TRUNCATE + INSERT
Objets par couche	Bronze/Silver = tables physiques ; Gold = vues
Documentation	Diagrammes d'architecture, normes d'implémentation et versionnement Git

- **Création** de la base SQL Server et des trois schémas.
- **Préparation** de la structure du dépôt Git et documentation des règles d'implémentation pour l'équipe.

3. Réalisation technique, résultats et prochaines étapes

A. Couche Bronze terminée

- Création de bronze.dealer_car_sales pour conserver les neuf colonnes sources sous forme de texte brut, avec ajout des métadonnées de chargement.

- Mise en place de l'ingestion par lots depuis le CSV avec BULK INSERT et une table temporaire correspondant aux colonnes sources.
- Chargement des 2 500 000 lignes sans nettoyage ni transformation métier.
- Validation de la complétude, de la conformité du schéma et des métadonnées source.

B. Couche Silver terminée

- Profilage des données Bronze : valeurs nulles, doublons, types invalides, espaces, plages numériques et cohérence des commissions.
- Création de silver.dealer_car_sales avec les types SQL appropriés et une procédure de chargement complet.
- Application du trim, du traitement des valeurs vides, des conversions de types et de la suppression des caractères de contrôle.
- Réconciliation des volumes Bronze/Silver : 2 500 000 lignes dans chaque couche.

Indicateur de validation	Résultat
Valeurs manquantes	0
Transactions exactement dupliquées	0
Valeurs date/année/prix/taux invalides	0
Incohérences de commission	0
Période des ventes	01/05/2022 au 01/05/2023
Années des véhicules	2010 à 2022
Plage des prix de vente	10 000,00 à 50 000,00

C. Problème identifié et résolu

Problème : La dernière colonne du CSV, commission_earned, contenait un caractère de retour chariot masqué (CHAR(13)), qui empêchait initialement la conversion numérique. Les données Bronze ont été conservées telles quelles ; le caractère a été supprimé uniquement lors de la transformation Silver. La validation finale des commissions n'a relevé aucune incohérence.

D. Prochaines étapes

- Concevoir le schéma en étoile Gold et créer les vues : dim_date, dim_car, dim_customer, dim_salesperson et fact_car_sales.
- Valider les règles métier Gold et créer le catalogue de données ainsi que le diagramme du schéma en étoile.
- Connecter Power BI à la couche Gold et démarrer le modèle de reporting ainsi que les mesures KPI.