

ENTREPÔT DE DONNÉES DES VENTES AUTOMOBILES

Normes d'implémentation, conventions de nommage et règles d'exécution

Projet : Entrepôt de données des ventes automobiles

Objet. Ce document constitue la norme d'exécution du projet. Chaque contributeur doit respecter l'architecture, les types d'objets, les méthodes de chargement, les conventions de nommage, les règles de validation et la séquence de livraison définis ci-dessous.

Référentiel du projet

Élément	Norme
Base de données	car_sales_dwh
Source	CSV Kaggle : car_sales_data.csv (environ 2,5 millions de transactions)
ETL	T-SQL uniquement
Plateforme de base de données	SQL Server / SSMS
BI et analytique	Power BI, SQL ad hoc, Python pour le ML, Streamlit
Schémas	bronze, silver, gold

Flux d'architecture obligatoire



1. Architecture et responsabilités des couches

Couche	Type d'objet	Méthode de chargement	Transformation	Modèle	Public cible
Bronze	Table physique	Chargement complet par lots : TRUNCATE + INSERT	Données brutes telles que reçues ; aucune transformation	Aucun modèle de données	Data engineers
Silver	Table physique	Chargement complet par lots : TRUNCATE + INSERT	Nettoyage, standardisation, typage, normalisation, colonnes dérivées et enrichissement	Aucun modèle de données	Data engineers et analystes
Gold	Vues	Aucun chargement physique	Intégration, agrégation, logique métier et présentation analytique	Schéma en étoile, agrégats et vues analytiques à plat	Analystes et utilisateurs métier

Règles de la couche Bronze

- Conserver toutes les lignes et toutes les valeurs sources exactement telles qu'elles ont été reçues.
- Ne pas supprimer les doublons, remplacer les valeurs nulles, standardiser les textes, convertir les types de données métier ni appliquer de règles métier.
- Des colonnes de métadonnées peuvent être ajoutées sans modifier les valeurs sources : dwh_load_date, dwh_source_system et dwh_source_file.
- Les champs sources bruts doivent rester au format texte lorsque cela est nécessaire pour préserver fidèlement les données d'entrée.

Règles de la couche Silver

- Lire uniquement depuis la couche Bronze. La couche Silver ne doit jamais lire directement le fichier CSV.
- Commencer par profiler la couche Bronze, puis définir les transformations, charger la couche Silver et exécuter les contrôles de conformité.
- Nettoyer les caractères de contrôle, supprimer les espaces superflus, convertir les chaînes vides en NULL, appliquer les types SQL appropriés et valider les champs obligatoires.
- Détecter les doublons et appliquer la règle de déduplication documentée. Ne supprimer aucun enregistrement sans règle explicite et reproductible.
- Le jeu de données actuel conserve les 2 500 000 lignes, car le profilage n'a identifié aucun enregistrement manquant ni doublon exact.

Règles de la couche Gold

- Lire uniquement depuis la couche Silver.
- Créer des vues prêtes à l'usage métier ; dans l'architecture actuelle, ne pas utiliser TRUNCATE, INSERT ni de procédures de chargement pour la couche Gold.
- Représenter le schéma en étoile au moyen de vues de dimensions et de faits, et ajouter des agrégats ou des vues analytiques à plat uniquement lorsqu'ils sont nécessaires aux consommateurs.
- Power BI, les requêtes SQL ad hoc, l'apprentissage automatique et Streamlit doivent consommer les objets Gold, et non les objets Bronze ou Silver.

2. Conventions de nommage

Élément	Règle	Exemples
Règle générale	snake_case	dealer_car_sales, commission_earned
Langue	Anglais	sale_date, customer_name
Base de données	car_sales_dwh	Une base de données pour le projet
Schémas	bronze, silver, gold	Un schéma par couche de l'architecture médaille
Objets Bronze / Silver	<source_system>_<entity>	dealer_car_sales
Objets Gold	<category>_<entity>	dim_car, fact_car_sales
Clés de substitution	<entity>_key	car_key, customer_key, date_key
Colonnes de métadonnées	dwh_<attribute>	dwh_load_date, dwh_source_file
Colonnes de date	<attribute>_date	sale_date, dwh_load_date
Colonnes booléennes	is_<condition> ou has_<condition>	is_active, has_forecast
Procédures stockées	load_<layer>_<entity>	load_silver_dealer_car_sales

Qualification des objets

- Toujours référencer les objets avec le schéma et le nom de l'objet, par exemple bronze.dealer_car_sales.
- Créer les procédures de chargement dans le schéma de la couche cible, par exemple silver.load_silver_dealer_car_sales.
- Ne pas créer d'objets génériques dans dbo sans approbation explicite.

Inventaire des sources et des objets principaux

Zone	Type	Objet	Finalité
Source	Fichier CSV	car_sales_data.csv	Neuf colonnes sources ; une ligne par transaction de vente
Bronze	Table	bronze.dealer_car_sales	Valeurs sources brutes et métadonnées DWH
Silver	Table	silver.dealer_car_sales	Données transactionnelles nettoyées, standardisées et correctement typées
Gold	Vue	gold.dim_date	Dimension Date
Gold	Vue	gold.dim_car	Dimension Marque, modèle et année du véhicule
Gold	Vue	gold.dim_customer	Dimension Client
Gold	Vue	gold.dim_salesperson	Dimension Vendeur
Gold	Vue	gold.fact_car_sales	Représentation des faits de vente
Gold	Vue	gold.fact_forecast	Résultats des prédictions lorsque la couche ML est mise en œuvre

Colonnes sources

date, salesperson, customer_name, car_make, car_model, car_year, sale_price, commission_rate, commission_earned

3. Règles ETL, de transformation et de validation

Périmètre technologique

Zone	Technologie approuvée
Base de données et ETL	SQL Server / SSMS et T-SQL uniquement

Zone	Technologie approuvée
Diagrammes de données	Draw.io
Informatique décisionnelle	Power BI Desktop
Apprentissage automatique	Python : pandas, scikit-learn et Prophet
Tableau de bord web	Python : Streamlit
Gestion de versions	Git et GitHub

Règles d'exécution des chargements

- Les chargements Bronze et Silver sont des chargements complets par lots, utilisant TRUNCATE TABLE suivi de INSERT.
- Utiliser une procédure stockée pour chaque chargement et exécuter le chargement dans une transaction.
- Utiliser SET XACT_ABORT ON ainsi qu'un bloc TRY/CATCH. Annuler la transaction lorsqu'une erreur se produit.
- Capturer un seul horodatage de chargement par lot et l'appliquer à toutes les lignes du lot.
- Valider le nombre de lignes de la source et de la cible avant de valider définitivement le chargement.
- Arrêter le chargement lorsque des champs obligatoires ou des conversions de type sont invalides. Ne jamais écarter silencieusement des lignes.

Processus Silver obligatoire

Étape	Action obligatoire
1. Analyser	Explorer la couche Bronze, compter les enregistrements et analyser les valeurs nulles, les valeurs invalides, les doublons, les plages, les espaces et les caractères de contrôle.
2. Développer	Écrire des transformations T-SQL déterministes et charger silver.dealer_car_sales.
3. Valider	Vérifier le rapprochement des lignes, la conformité des types, les plages de valeurs et la cohérence métier.

Transformations Silver propres au projet actuel

- Convertir sale_date en DATE en utilisant le style ISO 23.
- Convertir car_year en SMALLINT.
- Convertir sale_price et commission_earned en DECIMAL(18,2).
- Convertir commission_rate en DECIMAL(20,18) afin de préserver la précision de la source.
- Supprimer les espaces superflus des champs texte et convertir les chaînes vides en NULL.
- Supprimer CHAR(13) et CHAR(10) de commission_earned avant la conversion numérique.
- Valider commission_earned par rapport à sale_price × commission_rate avec une tolérance de 0,01.

Critères minimaux de qualité

Jalon de contrôle	Règle d'acceptation
Chargement Bronze	Le nombre de lignes de la source correspond à celui de la couche Bronze ; les métadonnées sont renseignées.
Précontrôle Silver	Aucune valeur nulle obligatoire non traitée ni conversion échouée.
Rapprochement Silver	Le nombre de lignes Silver correspond au résultat de transformation approuvé.
Conformité Silver	Les plages de valeurs sont plausibles et le calcul des commissions est cohérent.
Validation Gold	Les clés de dimensions sont uniques ; les jointures de faits ne génèrent ni correspondances manquantes ni doublons.
Validation des consommateurs	Les chiffres de Power BI, du ML et de Streamlit concordent avec les résultats SQL de la couche Gold.

4. Séquence d'exécution et liste de contrôle des livrables

1. Valider le cahier des charges, le périmètre et les indicateurs clés de performance requis.

2. Créer car_sales_dwh ainsi que les schémas bronze, silver et gold.
3. Créer bronze.dealer_car_sales et charger le fichier CSV sans transformation métier.
4. Profiler la couche Bronze et documenter tous les problèmes de qualité des données détectés.
5. Créer et charger silver.dealer_car_sales en appliquant les règles de nettoyage approuvées.
6. Valider la couche Silver et la rapprocher de la couche Bronze.
7. Créer les vues Gold du schéma en étoile ainsi que les vues analytiques.
8. Connecter Power BI à la couche Gold et créer les mesures ainsi que les pages du tableau de bord.
9. Construire et évaluer le modèle de prédiction, puis exposer les prévisions à travers la couche Gold.
10. Construire le tableau de bord Streamlit et le valider par rapport aux données Gold.

Structure de dépôt recommandée

```

car-sales-data-warehouse/
├── datasets/           # Échantillon local facultatif ; ne pas versionner de fichiers volumineux ou privés
├── docs/              # CDC, architecture, catalogue de données et preuves de validation
├── scripts/
│   ├── init/          # Création de la base de données et des schémas
│   ├── bronze/        # Table Bronze et procédure de chargement
│   ├── silver/        # Table Silver, procédure de chargement et validations
│   └── gold/          # Vues Gold et requêtes de validation
├── powerbi/           # Fichier PBIX et documentation
├── ml/                # EDA, entraînement, évaluation et résultats des prévisions
├── streamlit/         # Application du tableau de bord web
└── README.md

```

Liste de contrôle du contributeur avant une pull request

- ☐ Les noms d'objets respectent la convention snake_case approuvée.
- ☐ Toutes les références SQL incluent le nom du schéma.
- ☐ Les valeurs Bronze restent inchangées, à l'exception des métadonnées ajoutées.
- ☐ Les transformations Silver sont documentées et reproductibles.
- ☐ Les objets Gold sont des vues et lisent uniquement depuis la couche Silver.
- ☐ Les scripts peuvent être réexécutés et ne dépendent d'aucune modification manuelle entre les exécutions.
- ☐ Les requêtes de validation sont incluses et leurs résultats sont documentés.
- ☐ Aucun mot de passe, identifiant ou secret propre à une machine n'est versionné.
- ☐ Le README et le catalogue de données sont mis à jour lorsqu'un objet est modifié.